

2023-2025年強化學習領域頂尖論文綜述

近年來強化學習(RL)領域取得了許多突破性進展，特別是在離線RL、安全RL、決策轉換器等方向。本報告將統整2023-2025年發表於頂尖會議期刊的重要RL論文，深入分析其技術精神和概念核心。

離線強化學習的創新方法

Constrained Decision Transformer (CDT) - 離線安全強化學習

新觀察與觀點：傳統安全強化學習(Safe RL)通常需要與環境互動來訓練滿足約束的策略。2023年發表的這項研究首次從多目標優化視角提出了在離線環境中學習安全策略的新方法，並引入" ϵ -reducible"概念來表徵問題難度^[1]。

解決方案：作者提出了約束決策轉換器(Constrained Decision Transformer, CDT)，該方法能在部署過程中動態調整安全性和任務性能之間的權衡^[1]。

運作原理：CDT方法將安全性與任務性能視為多目標優化問題，基於決策轉換器架構，增加了在不同約束閾值間進行零樣本適應的能力，平衡安全與性能需求^[1]。

改善成效：實驗證明CDT比其變體和強基線離線安全RL方法表現更佳，能夠在保持相同超參數的情況下適應不同約束閾值，使其更適合實際場景應用^[1]。

理論貢獻：論文從多目標優化角度為離線安全RL提供了新視角，" ϵ -reducible"概念為安全RL問題難度量化提供了理論基礎^[1]。

Implicit Diffusion Q-Learning (IDQL)

新觀察與觀點：研究者重新解釋了隱式Q學習(IQL)作為一種演員-評論家方法，指出現有方法無法清楚表明哪種策略能實現隱式訓練Q函數所代表的價值，特別是當隱式演員具有複雜多模態特性時^[2]。

解決方案：作者提出隱式擴散Q學習(IDQL)，將廣義IQL評論家與基於擴散模型的策略提取方法相結合^[2]。

運作原理：IDQL使用擴散參數化的行為策略生成樣本，並利用從評論家計算的權重通過重要性採樣獲得目標策略，有效處理了複雜分布的策略表示問題^[2]。

改善成效：IDQL保留了IQL易於實現的特點，同時在性能上超越了先前的離線RL方法，並對超參數顯示出高度穩健性^[2]。

理論貢獻：論文建立了IQL與演員-評論家方法的理論連接，闡明了如何從隱式訓練的Q函數中提取優化策略，拓展了對行為策略與最優策略關係的理解^[2]。

Projection Implicit Q-Learning (Proj-IQL)

新觀察與觀點： 2025年的這項研究指出，雖然隱式Q學習(IQL)通過期望回歸有效緩解了分布外(OOD)動作風險，但其策略評估中的固定超參數和基於密度的策略改進方法限制了整體效率^[3]。

解決方案： 研究者提出了Proj-IQL，一種增強支持約束的投影式IQL算法^[3]。

運作原理： Proj-IQL在策略評估階段通過向量投影將單步方法擴展為多步方法，同時保持樣本內學習和期望回歸框架；策略改進階段則引入更符合策略評估方法的支持約束^[3]。

改善成效： 實驗表明，Proj-IQL在D4RL基準上實現了最先進性能，特別是在具挑戰性的導航領域中表現優異^[3]。

理論貢獻： 理論分析證明Proj-IQL保證單調策略改進，並提供了對優質動作的逐步更嚴格篩選標準^[3]。

AlignIQL: 隱式Q學習中的策略對齊

新觀察與觀點： 研究者注意到雖然隱式Q學習(IQL)作為離線RL基線表現出色，但不清楚為何可以使用加權回歸進行策略提取，以及如何從學習的隱式Q函數中恢復最優策略^[4]。

解決方案： 提出了AlignIQL和AlignIQL-hard兩種算法，將隱式策略查找問題(IPF)公式化為約束優化問題^[4]。

運作原理： 這些方法繼承了IQL中將演員與評論家解耦的優勢，通過優化框架解決策略提取問題，為隱式Q學習提供理論支持^[4]。

改善成效： 在D4RL數據集上的實驗顯示，該方法比其他頂尖離線RL方法表現更佳，特別是在Antmaze和Adroit等複雜稀疏獎勵任務中，大幅超越IQL和IDQL^[4]。

理論貢獻： 論文提供了對隱式策略查找的理論框架，解釋了IQL加權回歸有效性的原因，為離線RL策略優化提供新視角^[4]。

決策轉換器的進階發展

Elastic Decision Transformer (EDT)

新觀察與觀點： 研究者發現傳統決策轉換器(DT)雖然聲稱能生成最優軌跡，但實際上在軌跡拼接方面存在困難，無法從次優軌跡組合中提取最佳部分^[5]。

解決方案： 提出彈性決策轉換器(EDT)，通過動態調整歷史保留長度實現測試時的軌跡拼接^[5]。

運作原理： EDT在前一軌跡表現優異時保留較長歷史，在次優時保留較短歷史，使其能與更優軌跡"拼接"，從而實現動態優化^[5]。

改善成效： 實驗證明EDT能彌合基於DT和基於Q學習方法之間的性能差距，特別是在D4RL運動基準和Atari遊戲的多任務場景中，EDT優於傳統Q學習方法^[5]。

理論貢獻： 論文引入軌跡拼接概念，展示了如何通過歷史長度調整來優化序列模型性能，為基於轉換器的RL提供新思路^[5]。

HarmoDT: 和諧多任務決策轉換器

新觀察與觀點：2024年的研究指出，離線多任務強化學習(MTRL)面臨任務內容和複雜性變化帶來的挑戰，需要精心設計參數共享機制並管理衝突梯度以獲得最佳策略^[6]。

解決方案：作者提出和諧多任務決策轉換器(HarmoDT)，旨在為每個任務識別最優參數子空間^[6]。

運作原理：HarmoDT將多任務學習視為雙層優化問題，採用元學習框架：上層學習特定任務的參數掩碼(定義和諧子空間)，下層優化參數以提升整體性能^[6]。

改善成效：實驗評估證明了HarmoDT在多任務RL基準上的優越性，解決了參數共享和梯度衝突問題^[6]。

理論貢獻：論文提出了一套新的元學習框架解決多任務參數共享問題，為決策轉換器在多任務場景的應用提供理論基礎^[6]。

In-Context Decision Transformer (IDT)

新觀察與觀點：研究者注意到現有上下文學習方法雖能實現試錯式自我改進，但當跨情景序列隨任務範圍增加時面臨高計算成本問題^[7]。

解決方案：提出上下文決策轉換器(IDT)，通過層次化思想鏈實現高效的高層級試錯自我改進^[7]。

運作原理：IDT受人類決策的層次結構啟發，將序列重構為高級決策而非低級動作，一個高級決策可指導多步低級行動，避免過長序列並提高效率^[7]。

改善成效：實驗表明IDT在長期任務中表現優於現有上下文RL方法，在D4RL基準中評估速度比基線快36倍，在Grid World基準中快27倍^[7]。

理論貢獻：論文將層次化思想鏈(Hierarchical Chain-of-Thought)概念引入RL領域，為高效離線RL提供了新型思維框架^[7]。

人類反饋強化學習的創新

探索性偏好優化 (XPO)

新觀察與觀點：研究者發現人類反饋強化學習(RLHF)中的在線探索方法要麼計算成本過高，要麼在適應現有RL技術時遇到統計瓶頸^[8]。

解決方案：提出探索性偏好優化(Exploratory Preference Optimization, XPO)算法，對直接偏好優化(DPO)進行簡單修改，但具有更強理論保證^[8]。

運作原理：XPO在DPO目標中增加新型探索獎勵，使算法能探索初始模型支持範圍之外的區域，平衡探索與最優化^[8]。

改善成效：理論上，XPO在滿足自然探索條件下能高效利用樣本、收斂到近乎最優的語言模型策略，不受初始模型覆蓋質量限制^[8]。

理論貢獻：分析表明DPO隱式執行了Q*近似形式，為RLHF中的策略優化提供新視角，建立了RLHF與傳統RL的理論連接^[8]。

應用領域的強化學習創新

能源社區電池控制的強化學習

新觀察與觀點： 研究表明基於規則的控制器(RBCs)雖簡單但無法適應新環境和不確定性，而RL代理能從環境交互中學習並更好地適應變化^[9]。

解決方案： 作者提出結合MaskPPO和深度神經網絡的新型RL方法，避免探索不安全/不盈利動作，並通過準確預測未來需求增強控制效能^[9]。

運作原理： 該方法在NeurIPS 2022 CityLearn挑戰中應用，將真實世界數據嵌入模擬器進行分布式電池控制，結合動作掩碼限制探索空間並使用神經預測器提高決策質量^[9]。

改善成效： RL代理對分布式電池提供了強大控制，優於基於規則的控制器。動作掩碼與神經預測器的結合顯著提升了RL代理性能，接近全局最優解^[9]。

理論貢獻： 研究證明動作掩碼與神經預測結合能大幅提高RL在控制問題中的表現，為能源管理系統中的分布式控制提供新理論框架^[9]。

總結與未來展望

2023-2025年強化學習領域的創新主要集中在離線RL、決策轉換器、多任務學習和人類反饋學習等方向。這些研究通過重新解釋現有方法、引入新視角和優化技術，顯著提升了RL在複雜任務中的性能與效率。

未來強化學習研究可能會更加關注：

1. 層次化決策與抽象表示學習
2. 多任務和元學習框架下的知識遷移
3. 與大型語言模型的深度融合
4. 在實際部署中的安全性和穩健性保證

這些進展不僅推動了理論發展，也為實際應用問題提供了新的解決方案，展現了強化學習在複雜決策系統中的巨大潛力。

研究方法論創新

這些頂尖研究不僅提出了新算法，還創新了研究方法論，包括重新解釋現有算法框架、從多目標優化角度思考RL問題、引入約束優化視角，以及將層次化思維引入RL範式。這些方法論創新為解決更複雜的實際問題提供了新思路，也預示著強化學習研究將向更加理論化和系統化的方向發展。



1. <https://arxiv.org/abs/2302.07351>
2. <https://arxiv.org/abs/2304.10573>
3. <https://arxiv.org/abs/2501.08907>
4. <https://arxiv.org/abs/2405.18187>
5. <https://arxiv.org/abs/2307.02484>

6. <https://arxiv.org/abs/2405.18080>

7. <https://arxiv.org/abs/2405.20692>

8. <https://arxiv.org/abs/2405.21046>

9. <https://www.semanticscholar.org/paper/2e9fdda545e25b428bd9a00009140b5b39195791>